

Assistentes de IA vs. codificação manual: um experimento controlado

Relatório Final — Laboratório 02

1. Introdução

Assistentes de IA generativa passaram a fazer parte da rotina de desenvolvimento, acompanhados da alegação recorrente de que permitem resolver tarefas de programação *mais rápido e com menos erros*. Este trabalho testa essa alegação por meio de um experimento controlado, comparando a resolução de katas de programação **com** e **sem** o apoio de um assistente de IA.

Objetivo (GQM). Analisar o uso de assistentes de IA generativa na resolução de tarefas de programação, com o propósito de comparar seu efeito frente à codificação manual, com respeito a tempo de resolução, qualidade funcional (defeitos) e qualidade estrutural do código produzido, do ponto de vista do grupo pesquisador, no contexto de katas de dificuldade equivalente resolvidas por estudantes de graduação sob condições controladas (crossover *within-subject*, time-box de 35 minutos).

Questões de pesquisa

- **RQ1 — Tempo:** o uso do assistente reduz o tempo de resolução (*time-to-green*)?
- **RQ2 — Defeitos:** o uso do assistente aumenta a taxa de testes de aceitação passando?
- **RQ3 — Estrutura:** o uso do assistente altera a complexidade ciclomática e a duplicação do código?

Hipóteses

As hipóteses e a direção de cada teste foram declaradas **antes** da coleta, para impedir a escolha do teste após ver os dados. Nível de significância $\alpha = 0,05$ em todas as RQs.

RQ	H0 (nula)	H1 (alternativa)	Cauda
RQ1 — tempo	$\text{mediana}(\text{tempo_IA}) = \text{mediana}(\text{tempo_MANUAL})$	$\text{mediana}(\text{tempo_IA}) < \text{mediana}(\text{tempo_MANUAL})$	unicaudal
RQ2 — defeitos	$\text{mediana}(\text{sucesso_IA}) = \text{mediana}(\text{sucesso_MANUAL})$	$\text{mediana}(\text{sucesso_IA}) > \text{mediana}(\text{sucesso_MANUAL})$	unicaudal
RQ3 — estrutura	$\text{mediana}(\text{métrica_IA}) = \text{mediana}(\text{métrica_MANUAL})$, para complexidade e duplicação	as medianas diferem	bicaudal

RQ1 e RQ2 são unicaudais porque a alegação corrente sobre assistentes de IA é direcional ("resolve mais rápido e com menos erro"). RQ3 é bicaudal porque não há direção consensual: é plausível tanto que a IA produza código mais verboso e duplicado quanto mais idiomático e enxuto.

2. Metodologia

Esta seção descreve o experimento com detalhe suficiente para reprodução (mesmos artefatos e scripts) e replicação (novo grupo, mesmo protocolo). Todos os artefatos citados estão no repositório.

2.1 Variáveis

Tipo	Variável	Operacionalização
Independente	Uso do assistente de IA	fator único, dois níveis: IA e MANUAL
Dependente (RQ1)	time-to-green (s)	segundos entre o início do trial e a primeira execução com a suíte 100% verde; trial que estoura o time-box é censurado em 2100 s , nunca descartado
Exploratória (RQ1)	nº de prompts	interações enviadas ao assistente, auditáveis pelo log da conversa
Dependente (RQ2)	taxa de sucesso	(tests – failures – errors) / tests, lida do XML JUnit do Jest
Dependente (RQ3)	complexidade ciclomática	McCabe por função (regra <i>complexity</i> do ESLint); reportada como média, máximo, soma e soma/LOC
Dependente (RQ3)	% de linhas duplicadas	jscpd (minTokens 25, minLines 3), apenas sobre <i>src/</i>
Controle (RQ3)	LOC	linhas não vazias e não comentadas

O termo *errors* entra no cálculo da taxa de sucesso porque o esqueleto das katas lança `Error("TODO")`; sem ele, um trial sem nenhuma linha escrita apareceria com 100%. A complexidade é reportada em quatro variantes porque o ESLint conta callbacks de `.filter()/map()` como funções, o que faria a média por função medir estilo (laço vs. *array method*) em vez de complexidade.

2.2 Tratamentos e assistente de IA

Nível	Permitido	Proibido
IA	Claude (claude.ai, plano gratuito — modelo padrão oferecido pelo plano na data da coleta, 15 a 17/09/2026); documentação oficial; busca na web	qualquer outro assistente
MANUAL	documentação oficial (MDN, TypeScript Handbook); busca na web	qualquer assistente de IA, incluindo autocomplete de IA na IDE (Copilot, Cursor, Tabnine etc.), desligado antes do trial

A documentação fica liberada nos dois tratamentos de propósito: o contraste de interesse é "com IA vs. codificação manual", e não "com IA vs. sem nenhum recurso". O mesmo assistente foi usado em todos os trials do grupo. O log de cada conversa com o Claude foi arquivado junto do trial.

2.3 Objetos experimentais — katas

Seis katas em TypeScript, todas no mesmo molde: uma única função exportada, pura e determinística, sobre tipos básicos, sem I/O nem concorrência, com **12 testes de aceitação** autorais em Jest. Todas derivam de exercícios públicos e foram **reescritas** para que a solução canônica não passe direto na suíte (mitigação da ameaça de memorização).

#	Kata	Origem	Alteração em relação ao original
K1	Compressor de faixas	Codewars <i>Range Extraction</i>	separador <code>..</code> em vez de <code>-</code> ; entrada admite valores repetidos
K2	Leitura em espiral	Codewars <i>Snail Sort</i>	sentido anti-horário; matriz retangular M×N
K3	Duração legível	Codewars <i>Human Readable Duration</i>	saída em português com plural; semana entra, ano sai; negativo lança <code>RangeError</code>
K4	Numeral romano	LeetCode #13	exige rejeitar numeral malformado (o original garante entrada válida)
K5	Alcance da rainha	clássico de entrevista	tabuleiro retangular com casas bloqueadas
K6	Delimitadores balanceados	LeetCode #20	trechos entre aspas são literais; aspa não fechada invalida

Calibração. Medida sobre a solução de referência de cada kata: LOC de 18 a 30, CC máximo de 7 a 13, 12 testes em todas. O esqueleto entregue dá 12 falhas em 12 testes; a referência, 0 falhas. A

calibração é estrutural, não empírica (nenhum piloto cronometrado com pessoas).

2.4 Desenho experimental

Crossover within-subject contrabalanceado: cada um dos 3 integrantes resolve as 6 katas, 3 com IA e 3 sem, sem repetir kata. Total: **18 trials** (9 IA, 9 MANUAL), time-box de **35 minutos** por trial e intervalo mínimo de 10 minutos entre trials do mesmo integrante. Alocação planejada (quadrado latino adaptado):

	1º	2º	3º	4º	5º	6º
P1	K1 · IA	K2 · MAN	K3 · IA	K4 · MAN	K5 · IA	K6 · MAN
P2	K3 · MAN	K4 · IA	K5 · MAN	K6 · IA	K1 · MAN	K2 · IA
P3	K5 · IA	K6 · MAN	K1 · MAN	K2 · IA	K3 · MAN	K4 · IA

Desvio de execução. 8 dos 18 trials foram executados fora da alocação planejada (os seis de P2 e dois de P3). O balanço 9 IA / 9 MANUAL e o "3 + 3 por integrante" foram preservados, mas K1 recebeu só IA e K6 só MANUAL, o que reduziu os pares do teste pareado de 6 para 4 (ver 2.7).

2.5 Ambiente e instrumentação

Item	Versão / configuração
Linguagem	TypeScript 5.9.3 (ts-jest 29.4.12)
Runtime	Node.js 20+ exigido (validado em 22.13 e 23.11), npm 10+
Testes	Jest 29.7.0 + jest-junit 17.0.0 (relatório JUnit XML)
Complexidade	ESLint 9.39.5 + @typescript-eslint/parser 8.70.0, regra <i>complexity</i> com limite 0
Duplicação	jscpd 4.3.0, minTokens 25, minLines 3, ignora <i>test/</i>
Análise	Python 3.13, pandas 2.2.3, scipy 1.18.1, matplotlib 3.9.4, seaborn 0.13.2
Sistema	Windows 11, PowerShell 5.1
Assistente	Claude, via claude.ai, plano gratuito

As versões estão fixadas no package-lock.json e são instaladas com npm ci pelo setup_ambiente.ps1, garantindo instrumentação idêntica nas três máquinas. O run_trial.ps1 cria um workspace isolado por trial, reexecuta a suíte a cada mudança em src/, encerra no primeiro verde ou no estouro do time-box e grava uma linha em data/trials.csv. Autotestes (test_run_trial.ps1, test_run_metrics.ps1) verificam censura, verde e ambiente quebrado, e 25 valores de métrica contados à mão.

2.6 Procedimento de reprodução

```
.\scripts\setup_ambiente.ps1
.\scripts\run_trial.ps1 -Integrante p1 -Kata kata-01-faixas -Tratamento IA -Ordem 1
.\scripts\run_metrics.ps1 -Todos
pip install -r analise\requirements.txt
python analise\consolidar_dados.py
python analise\rq1_rq2.py
python analise\rq3.py
python analise\dashboard.py
```

Nenhum número deste relatório foi digitado à mão: todos saem dos CSVs gerados pelos scripts. A consolidação descartou 3 execuções anteriores de trials repetidos (mantida sempre a mais recente, com registro em data/trials_descartados.csv).

2.7 Plano de análise estatística

- **Teste principal:** Wilcoxon signed-rank pareado por kata (mediana IA vs. mediana MANUAL em cada kata), com a kata como bloco. Parear por integrante é impossível, pois ninguém resolve a mesma kata nos dois tratamentos.
- **Teste secundário:** Mann-Whitney U sobre os 18 trials individuais (9×9), previsto desde o plano por causa do N pequeno do Wilcoxon.
- **Descritiva:** mediana e IQR, nunca média e desvio-padrão.
- **Tamanho de efeito** junto de todo p-valor: rank-biserial pareado (Wilcoxon) e Cliff's delta (Mann-Whitney).
- **Sensibilidade:** repetição dos testes sem os trials de P1 (autor das katas) e sem trials com cronometragem suspeita (< 30 s).

Limite de poder. Com apenas 4 pares, o menor p-valor que o Wilcoxon exato consegue produzir é **0,0625** (unicaudal) e **0,125** (bicaudal), ambos acima de α . Neste N o teste pareado **não pode rejeitar H_0** , por maior que seja o efeito; ele é lido como evidência de consistência de direção entre blocos, e o Mann-Whitney passa a ser o teste com poder.

3. Resultados

3.1 RQ1 — Tempo de resolução

Tratamento	n	Mediana (s)	Q1	Q3	IQR	Mín	Máx
IA	9	47	6	91	85	5	143
MANUAL	9	541	441	643	202	374	679

Nenhum trial foi censurado. A mediana com IA foi **91% menor**. Mais forte que a mediana é a **separação completa** das distribuições: o trial com IA mais lento (143 s) foi mais rápido que o trial manual mais rápido (374 s).




Figura 1 — RQ1: tempo até o verde por tratamento.

Kata	IA (s)	MANUAL (s)	Diferença	Par?
K1 faixas	50	—	—	não
K2 espiral	116	510	-394	sim
K3 duração	26	664	-638	sim
K4 romanos	91	661	-570	sim
K5 rainha	22	541	-519	sim
K6 delimitadores	—	440	—	não




Figura 2 — RQ1: mediana de tempo por kata (blocos do Wilcoxon).

Teste	n	Estatística	p-valor	Tamanho de efeito	Decisão
Wilcoxon pareado por kata	4	W = 0	0,0625	rank-biserial = -1,000	não rejeita H0 (sem poder)
Mann-Whitney U	18	U = 0	0,0002	Cliff's δ = -1,000 (grande)	rejeita H0
Mann-Whitney U — sem P1	12	U = 0	0,0025	Cliff's δ = -1,000	rejeita H0
Mann-Whitney U — sem cronômetro suspeito	15	U = 0	0,0002	Cliff's δ = -1,000	rejeita H0

O Wilcoxon atingiu exatamente o menor p-valor possível com 4 pares (as quatro diferenças são negativas); o "não rejeita" reflete falta de poder, não ausência de efeito. O Mann-Whitney dá U = 0 — nenhum trial manual foi mais rápido que qualquer trial com IA — e o resultado é estável nas duas análises de sensibilidade. Métrica exploratória: mediana de **1 prompt** por trial IA (máx. 2).

Resposta da RQ1: há evidência forte de que o uso do assistente reduziu o tempo de resolução neste contexto — 47 s contra 541 s, $p = 0,0002$ e tamanho de efeito máximo. **H0 rejeitada** pelo teste secundário.

3.2 RQ2 — Qualidade funcional

Tratamento	n	Mediana	IQR	Mín	Máx
IA	9	1,00	0,00	1,00	1,00
MANUAL	9	1,00	0,00	1,00	1,00

Os 18 trials terminaram com 12 de 12 testes passando. Com a variável dependente constante, os dois testes são **não aplicáveis** (Wilcoxon: diferença zero em todos os pares; Mann-Whitney: variância zero nos dois grupos) e, formalmente, H0 não é rejeitada.




Figura 3 — RQ2: taxa de sucesso por tratamento.

Resposta da RQ2: o experimento **não consegue responder**. Trata-se de um efeito teto causado pelo desenho — katas curtas, suíte visível durante o trial e time-box folgado (mediana manual abaixo de um terço do limite) —, e não de uma evidência sobre o assistente.

3.3 RQ3 — Estrutura do código

Complexidade ciclomática (média por função)

Tratamento	n	Mediana	Q1	Q3	IQR	Mín	Máx
IA	9	8	6	12	6	3	23
MANUAL	9	13	9	14	5	3	18

Kata	IA	MANUAL	Diferença (IA – MAN)
K2 espiral	11	14	–3
K3 duração	7,5	3	+4,5
K4 romanos	23	16	+7
K5 rainha	13	14	–1

Dentro da mesma kata a direção **se divide**: IA menos complexa em K2 e K5, mais complexa em K3 e K4. A mediana geral mais baixa da IA é, ao menos em parte, efeito de quais katas cada tratamento recebeu.




Figura 4 — RQ3: complexidade ciclomática e LOC por tratamento.

LOC (controle) e duplicação

LOC: mediana 33 (IA) contra 36 (MANUAL); o código de IA não foi sistematicamente mais verboso, apenas mais disperso (IQR 15 contra 6). Duplicação: mediana 0% nos dois tratamentos; apenas 1 dos 18 trials (p3-kata-04-romanos-ia, 2,44%) apresentou duplicação, o que torna os testes não aplicáveis.




Figura 5 — RQ3: percentual de linhas duplicadas por tratamento.

Métrica	Teste	n	p-valor	Tamanho de efeito	Decisão
CC média	Wilcoxon por kata	4	0,6250	rank-biserial = +0,400	não rejeita H0
CC média	Mann-Whitney U	18	0,1988	Cliff's δ = -0,370 (médio)	não rejeita H0

Métrica	Teste	n	p-valor	Tamanho de efeito	Decisão
CC soma / LOC	Wilcoxon por kata	4	0,2500	rank-biserial = -0,800	não rejeita H0
CC soma / LOC	Mann-Whitney U	18	0,1575	Cliff's δ = -0,407 (médio)	não rejeita H0
LOC	Wilcoxon por kata	4	0,6250	rank-biserial = +0,400	não rejeita H0
LOC	Mann-Whitney U	18	0,4003	Cliff's δ = -0,247 (pequeno)	não rejeita H0
% duplicado	ambos	—	não aplicável	—	1 de 18 trials

Na análise de sensibilidade (retirando cada integrante), nenhum recorte rejeita H0. O trial p3-kata-04-romanos-ia concentra sozinho o maior LOC (89), a maior complexidade (23) e a única duplicação, e não sustenta sozinho nenhuma afirmação sobre "o código da IA".

Resposta da RQ3: o experimento **não mostra** que o assistente altera a complexidade ou a duplicação do código. H0 não é rejeitada em nenhuma métrica, e os tamanhos de efeito dos dois testes apontam em sentidos opostos para a complexidade média.

3.4 Síntese




Figura 6 — Painel consolidado das três RQs.

RQ	Mediana IA	Mediana MANUAL	Wilcoxon (n = 4)	Mann-Whitney (n = 18)	Conclusão
RQ1 tempo	47 s	541 s	p = 0,0625; r = -1,00	p = 0,0002; δ = -1,00	H0 rejeitada: IA mais rápida
RQ2 sucesso	100%	100%	não aplicável	não aplicável	efeito teto
RQ3 CC média	8	13	p = 0,625; r = +0,40	p = 0,199; δ = -0,37	sem efeito consistente
RQ3 LOC	33	36	p = 0,625; r = +0,40	p = 0,400; δ = -0,25	sem diferença
RQ3 duplicação	0%	0%	não aplicável	não aplicável	1 de 18 trials

4. Discussão

O assistente acelerou a resolução — e só isso tem suporte nos dados. A RQ1 apresenta o efeito mais forte que o experimento poderia produzir: separação completa entre os tratamentos, Cliff's $\delta = -1,00$ e resultado estável retirando o autor das katas ou os trials de cronometragem suspeita. Já a frase "IA mais rápida e com código melhor" não pode ser escrita: a RQ2 saturou em 100% e, na RQ3, a mediana de complexidade menor da IA não se sustenta quando a comparação é feita dentro da mesma kata.

Memorização é a explicação concorrente principal. A mediana de 47 s com um único prompt é compatível com recuperação de solução conhecida, e não apenas com assistência efetiva. As katas foram reescritas para que a solução canônica não passasse direto na suíte, o que desloca o problema mas não o elimina — em especial em K4 (LeetCode #13) e K6 (LeetCode #20), entre os exercícios mais indexados que existem. Os logs das conversas, arquivados junto dos trials, permitem inspecionar quanto da resposta veio pronta.

O desenho discrimina tempo, mas não qualidade. Katas curtas, com especificação completa e suíte visível, levam qualquer participante competente a 100% de sucesso e deixam pouco espaço para duplicação (17 de 18 trials com 0%). A RQ2 e a duplicação da RQ3 são, portanto, limitações de desenho, e não achados sobre o assistente.

O desvio de execução custou o teste principal. Oito trials fora do quadrado latino deixaram K1 só com IA e K6 só com MANUAL, reduzindo o Wilcoxon a 4 pares — configuração em que ele não pode rejeitar H_0 em nenhuma RQ. Em conformidade com o plano, o teste não foi trocado após ver os dados; o Mann-Whitney já estava previsto como secundário. Em todos os casos, "não rejeitar H_0 " é lido como falta de poder, e não como ausência de efeito.

Ameaças à validade

- **Memorização / vazamento de solução** (principal) — mitigada pela reescrita das katas; risco residual declarado.
- **Contaminação do autor das katas** — P1 conhecia os casos de borda; análise de sensibilidade sem P1 mantém a conclusão da RQ1.
- **Cronometragem implausível** — 3 trials IA de P2 com 5–6 s indicam código escrito antes do início do cronômetro; a conclusão não muda sem eles.
- **Desvio do contrabalanceamento** — 8 de 18 trials fora do plano; P1 e P2 ficaram com a mesma alocação.
- **Efeito de expectativa** — os participantes são os próprios pesquisadores; mitigado por critérios objetivos (suíte automatizada e time-box).
- **Validade externa** — 3 estudantes e 6 katas algorítmicas curtas; os resultados não generalizam para manutenção de sistemas reais.
- **Calibração estrutural** — equivalência de dificuldade não validada com piloto humano.

Trabalhos futuros

- Alocação que dê os dois tratamentos a todas as katas (6 pares no Wilcoxon) e verificação da alocação antes de cada trial.
- Katas maiores, inéditas ou com suíte oculta, para tirar a RQ2 e a RQ3 do efeito teto e reduzir a memorização.
- Mais participantes, de fora do grupo pesquisador, e inspeção qualitativa dos logs de conversa.

5. Repositório e GitHub Projects

Código, katas, suítes de aceitação, scripts de coleta e análise, dados brutos e consolidados, e o board do GitHub Projects do grupo: <https://github.com/matheustitton/lab-medicao-experimentacao-6-periodo>