Mineração de métricas DORA em repositórios populares do GitHub

Matheus Ferreira Titton, Murilo Andrade Machado,
Pedro Henrique Barbosa Montandon de Araújo

Engenharia de Software – Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Laboratório de Experimentação de Software

Abstract. We measured the four DORA metrics (deployment frequency, lead time, change failure rate and time to restore) on 270 popular GitHub repositories that use GitHub Actions, taking releases, commits and workflow runs as proxies. The median frequency is 0.38 releases per week and the median lead time is about nine days. The change failure rate is 5.3% from CI and 40.0% from corrective releases, flagged by a heuristic validated against manual labels (F1 of 0.70). Repository age and number of contributors are associated with performance; stars and project type are not. Changing the operational definition moves 19% to 45% of the repositories to another DORA class.

Resumo. Medimos as quatro métricas DORA (frequência de deploy, lead time, taxa de falha e tempo de recuperação) em 270 repositórios populares do GitHub que usam GitHub Actions, com releases, commits e execuções de workflow como aproximações. A mediana de frequência foi de 0,38 releases por semana e a de lead time ficou perto de nove dias. A taxa de falha foi de 5,3% pelo CI e de 40,0% pelas releases corretivas, apontadas por uma heurística validada manualmente (F1 de 0,70). Idade e número de contribuidores se associam ao desempenho; estrelas e tipo de projeto, não. Trocar a definição operacional muda a classe DORA de 19% a 45% dos repositórios.

1. Introdução

As métricas DORA são a referência mais usada para medir o desempenho de entrega de software [Forsgren et al. 2018]. Elas supõem que se sabe quando houve um deploy e quando algo falhou. Em repositórios públicos esse registro não existe, e cada forma de aproximá-lo muda o resultado. Este trabalho aplica as quatro métricas a repositórios populares do GitHub e mede quanto a resposta depende da definição escolhida. Código, dados e análises estão disponíveis em `https://github.com/matheustitton/lab-medicao-experimentacao-6-periodo`.

Respondemos a sete questões de pesquisa e a uma questão bônus, com hipóteses escritas *antes* da coleta: **RQ01**, qual a frequência de deploys; **RQ02**, qual o lead time entre commit e deploy; **RQ03**, qual a taxa de falha das mudanças; **RQ04**, quanto tempo leva a recuperação após uma falha; **RQ05**, se maior frequência se associa a maior ou menor taxa de falha; **RQ06**, que características dos repositórios se associam ao desempenho; **RQ07**, quanto a classificação DORA depende da definição operacional; e **RQ08** (bônus), qual a taxa de retrabalho (*rework rate*). As hipóteses estão comparadas com os resultados na Seção 4.

2. Metodologia

2.1. Dados e seleção

Os dados vêm da API REST do GitHub, acessada por um cliente HTTP próprio, com paginação, controle do limite de taxa, *backoff* exponencial e cache em SQLite, o que torna a coleta retomável. A coleta ocorreu em 14 e 15 de outubro de 2026, sobre uma janela de 12 meses, de 01/10/2025 a 30/09/2026 (UTC).

A busca, fatiada por faixas de estrelas (mais de 1.000), devolveu 8.499 candidatos, processados em ordem pseudoaleatória reprodutível (semente 42). Os filtros, nesta ordem, foram: usar GitHub Actions, ter ao menos 5 releases principais na janela e ao menos 50 workflow runs válidos no *default branch*. Foram examinados 1.391 candidatos: 450 não usam Actions, 592 têm poucas releases, 78 têm poucos runs, 1 estava em processamento e **270 entraram na amostra**. A coleta parou antes de chegar aos 300 repositórios exigidos, o que declaramos como limitação.

2.2. Definições operacionais

Consideramos deploy uma release publicada (sem rascunhos nem pré-releases). Falha de CI é uma execução com `failure`, `timed_out` ou `startup_failure`; execuções canceladas ou ignoradas não entram. Medições cujo evento final não ocorre na janela são mantidas e contadas como censuradas. A Tabela 1 resume as métricas. Em todas as questões reportamos mediana e intervalo interquartil (IQR), porque as distribuições são muito assimétricas.

Tabela 1. Definição das métricas

Métrica	Definição
Frequência	releases na janela ÷ 52,1 semanas
Lead time (a)	data da release menos o commit mais antigo nela
Lead time (b)	um valor por commit; mediana sobre todos os commits
CFR (a), CI	falhas ÷ (falhas + sucessos)
CFR (b), entrega	releases seguidas, em até 7 dias, de release corretiva
Recuperação	da primeira falha após sucesso até o próximo sucesso

A classe de cada métrica usa os cortes da disciplina (Elite = 4, High = 3, Medium = 2, Low = 1), e a classe geral é a mediana dos pontos, arredondada para baixo. A coleta não baixou as tags do GitHub, então a combinação do enunciado que usa tags como unidade de entrega foi substituída por outra (C3, descrita na Seção 3.4).

2.3. Validação manual

Sorteamos 60 repositórios da amostra (semente 42) e 5 releases de cada, num total de 300. Os três autores rotularam, sozinhos, o tipo do projeto, se as releases são entregas reais e se cada release é corretiva. O consenso é a maioria de 2 em 3, com um desempate em reunião. A Tabela 2 mostra o kappa de Fleiss [Fleiss 1971], interpretado pela escala de Landis e Koch [1977].

O kappa baixo de “entregas reais” decorre do desbalanceamento (58 dos 60

Tabela 2. Concordância entre avaliadores

Dimensão	n	Kappa de Fleiss	Concordância bruta
Tipo do projeto	60	0,849 (quase perfeita)	85,0%
Release corretiva	300	0,739 (substancial)	80,7%
Releases são entregas reais	60	0,122	83,3%

repositórios "sim"), o chamado paradoxo do kappa. Essa dimensão não discrimina repositórios e não entra nas análises.

2.4. Heurística de release corretiva

O CFR (b) exige saber se uma release é corretiva. Testamos cinco versões de uma heurística contra o consenso, com meta de F1 de 0,70 (Tabela 3). A v4 ignora commits de *merge* e de dependência e exige uma fração de commits de correção; a v5 soma o intervalo curto desde a release anterior.

Tabela 3. Desempenho das versões da heurística

Versão	Regra resumida	Precisão	Recall	F1
v1	patch ou commit com `fix`/`revert`/`hotfix`	0,469	0,970	0,633
v2	patch e commit de correção	0,643	0,687	0,664
v3	patch pequeno ou com correção	0,594	0,754	0,664
v4	sem merges/dependências; $\geq$ 30% de correções	0,600	0,806	0,688
v5	v4 ou correção até 2 dias após a anterior	0,600	0,851	**0,704**

Como os limiares da v4 e da v5 foram ajustados nos mesmos rótulos, repetimos a escolha em validação cruzada por repositório (5 dobras): a F1 da v5 fora da amostra é **0,697**, um pouco abaixo da meta. Adotamos a v5. Com precisão de 0,60, o CFR (b) e o *rework rate* devem ser lidos como limites superiores.

2.5. Estatística e reprodutibilidade

Usamos correlação de Spearman (RQ05); Kruskal-Wallis com ε^2, na escala de Cohen [1988], e Mann-Whitney com δ de Cliff [Romano et al. 2006], ambos com correção de Holm [1979] (RQ06); e kappa ponderado linear (RQ07). Cada análise é um script reexecutável a partir do CSV. O código tem 196 testes, com cobertura de 100% do módulo de métricas. O dataset final tem 270 repositórios e 37 colunas, em 25 linguagens, com 13.664 releases, 1.046.247 commits e cerca de 800 mil workflow runs válidos. A mediana é de 15.705 estrelas, 168 contribuidores e 6,6 anos de idade.

3. Resultados

A Tabela 4 traz o panorama das RQ01 a RQ04.

Tabela 4. Mediana e IQR das métricas (270 repositórios)

RQ	Métrica	n	Mediana	Q1–Q3
RQ01	Frequência (releases/semana)	270	0,38	0,21–0,88
RQ02 (a)	Lead time por release (h)	270	235,6 (9,8 dias)	60,2–890,2
RQ02 (b)	Lead time por commit (h)	270	212,8 (8,9 dias)	55,2–706,7
RQ03 (a)	CFR de CI	270	5,3%	1,7%–12,2%
RQ03 (b)	CFR de entrega (v5)	270	40,0%	14,6%–66,7%
RQ04	Recuperação (h)	248	3,2	0,9–15,4

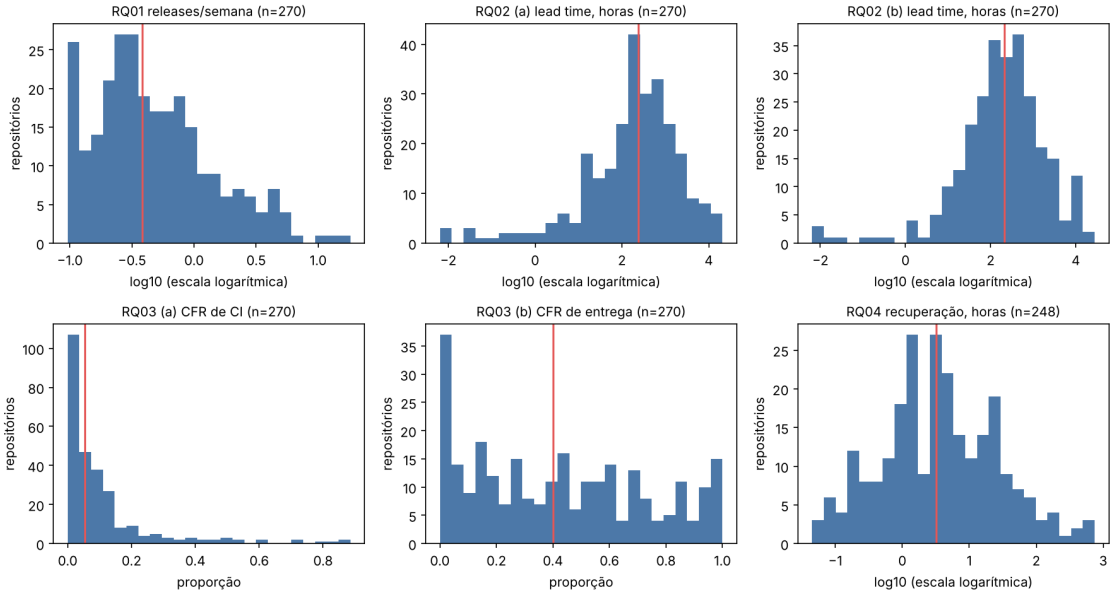


Figura 1. Distribuição das métricas nos 270 repositórios

3.1. RQ01 a RQ04

Frequência. A mediana equivale a uma release a cada 18 dias. Só 22% dos repositórios publicam ao menos uma por semana: 3 são Elite (1,1%), 56 High, 138 Medium e 73 Low.

Lead time. As duas variantes divergem menos do que esperávamos: (a) é maior que (b) em 63% dos repositórios, com razão mediana de 1,28, e elas se correlacionam fortemente ($\rho = 0{,}77$). Quem publica mais espera menos ($\rho = -0{,}59$ com a frequência), em parte por efeito mecânico.

Taxa de falha. O CFR (a) é baixo e 81,5% dos repositórios são Elite nele. O CFR (b) é alto e maior que o (a) em 78% dos repositórios; as duas variantes se correlacionam pouco ($\rho = 0{,}24$), pois medem coisas diferentes: falha de pipeline contra releases seguidas de correção. Como a heurística marca 63% das releases como corretivas contra 45% do consenso humano, o CFR (b) é um teto.

Recuperação. A mediana é de 3,2 horas, em 248 repositórios (22 não tiveram episódio e ficam sem valor, não zero). Dos 20.956 episódios, 140 (0,7%) foram censurados; em 19 repositórios a censura chega a 10% ou mais.

Classificação de referência (C1: release, lead time a, CFR a). Foram 21 repositórios Elite (7,8%), 108 High (40,0%), 117 Medium (43,3%) e 24 Low (8,9%). A frequência puxa a classe para baixo (só 22% em High ou Elite) e o CFR (a) para cima (91%).

3.2. RQ05: frequência e taxa de falha

Quanto maior a frequência, *maior* o CFR, o oposto do que o DORA sugere (Figura 2): $\rho = 0{,}25$ com o CFR (a), fraca, e $\rho = 0{,}73$ com o CFR (b), forte. A segunda é em parte mecânica, porque quem publica mais tem mais chance de ter uma release corretiva dentro dos 7 dias. A correlação é positiva com todas as versões da heurística (de 0,52 a 0,75). O resultado que sustenta a discussão é o da variante (a).

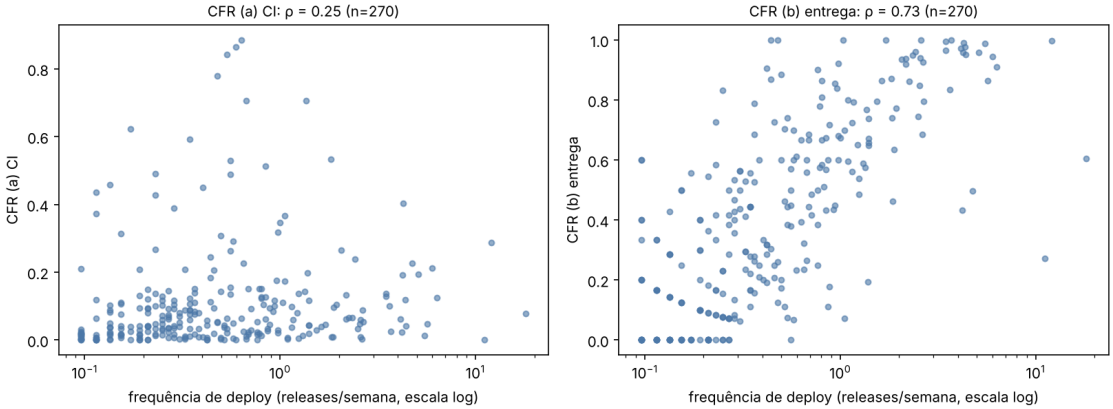


Figura 2. Frequência de deploy contra CFR (a) e (b)

3.3. RQ06: características dos repositórios

Cinco fatores (linguagem, estrelas, contribuidores, idade e tipo do projeto) contra seis métricas deram 30 testes, dos quais **9 continuam significativos após Holm** (Tabela 5). Estrelas e tipo do projeto não foram significativos; o tipo só existe para os 60 repositórios rotulados. Os repositórios mais velhos publicam menos (0,27 contra 0,81 releases por semana, $\delta = -0{,}61$) e têm lead time (a) muito maior (733 contra 27 horas, $\delta = 0{,}79$). Como a idade limita o lead time dos mais jovens, repetimos o Spearman só com os 230 repositórios de pelo menos um ano: a associação diminui mas persiste (frequência $\rho = -0{,}34$; lead time (a) $\rho = +0{,}38$), e a de recuperação desaparece.

3.4. RQ07: sensibilidade à definição

Comparamos quatro combinações: C1 (release, lead time a, CFR a), C2 (release e pré-release, lead time b, CFR b), C3 (release, lead time b, CFR a) e C4 (release, lead time a, CFR b). Entre 19% e 45% dos repositórios mudam de classe conforme a definição (Tabela 6). O que mais pesa é a variante do CFR: C1 e C3 têm 21 e 23 repositórios Elite, e C2 e C4 têm 4 e 2. A ordem relativa dos repositórios é mais estável do que as faixas (Spearman entre pontuações de 0,53 a 0,82). Contar as 4.119 pré-releases (em 98 repositórios) eleva a mediana de frequência de 0,38 para 0,46, e só 7,8% dos repositórios mudam de faixa. Entre as versões da heurística, 2% a 13% mudam de classe.

Tabela 5. Testes significativos após Holm (RQ06)

Fator	Métrica	ε^2	Magnitude
idade	lead time (a)	0,28	grande
idade	CFR (b)	0,26	grande
idade	lead time (b)	0,24	grande
idade	frequência	0,16	grande
contribuidores	lead time (b)	0,13	médio
contribuidores	lead time (a)	0,11	médio
linguagem	lead time (b)	0,09	médio
linguagem	lead time (a)	0,08	médio
idade	recuperação	0,06	pequeno

Tabela 6. Mudança de classe entre combinações (RQ07)

Par	Mudaram de classe	Kappa ponderado
C1 $\times$ C2	44,8%	0,37
C1 $\times$ C3	18,9%	0,76
C1 $\times$ C4	35,6%	0,54
C2 $\times$ C3	36,7%	0,52
C2 $\times$ C4	22,6%	0,64
C3 $\times$ C4	41,5%	0,44

3.5. RQ08 (bônus): rework rate

Com a v5, o *rework rate* tem mediana de 70% (IQR de 49% a 89%), contra 40% do CFR (b) ($\rho = 0{,}36$ entre eles). Ele é alto porque a heurística marca mais releases como corretivas do que o consenso.

4. Discussão

A Tabela 7 compara as hipóteses com os resultados.

O que mais surpreendeu foi o CFR (a) baixo e o (b) alto, o contrário do esperado. O CI do branch principal quase sempre passa, e o critério de 7 dias é fácil de cumprir para quem publica seguido, além de a heurística ter precisão de 0,60. Na prática o CFR (b) mede mais o ritmo de releases do que falhas, e **não** concluímos que esses projetos falham 40% das vezes. Os dados também não confirmam a tese do DORA de que velocidade e estabilidade andam juntas, mas não permitem a conclusão oposta: cada repositório aqui é um projeto de código aberto, e a frequência de releases reflete o estilo de versionamento (uma versão por correção, por exemplo) mais do que entrega contínua. Essa explicação não foi testada. A idade pesa mais do que a popularidade, embora parte desse efeito seja artefato de medição. Por fim, a definição operacional muda a resposta, sobretudo a variante do CFR, e rankings são mais confiáveis do que faixas absolutas.

Tabela 7. Hipóteses contra resultados

RQ	Encontrado	Veredito
RQ01	0,38/semana; 1,1% Elite	confirmada
RQ02	8,9 contra 9,8 dias; (a) $>$ (b) em 63%	parcial
RQ03	(a) 5,3%; (b) 40,0% e maior em 78%	só a baixa correlação
RQ04	3,2 h, cauda longa, 0,7% censurados	parcial
RQ05	ρ = 0,25 e 0,73	direção certa, força subestimada
RQ06	9 de 30 após Holm; idade e contribuidores	parcial
RQ07	19% a 45% mudam; κ de 0,37 a 0,76	parcial

4.1. Ameaças à validade

Construto. Release não é deploy. O CFR (a) mede falha de pipeline, e não de produção. O CFR (b) depende da heurística (precisão de 0,60) e é um limite superior. A dimensão "entregas reais" não foi validada (kappa de 0,12). O lead time usa a data de autoria do commit, distorcida por *rebase* e *squash* (22 repositórios).

Interna. Idade, contribuidores e frequência estão correlacionados e os fatores foram testados um de cada vez, sem regressão.

Externa. A amostra tem 270 repositórios, abaixo dos 300 exigidos. Foram descartados 592 candidatos por terem poucas releases, justamente os de menor frequência. Os resultados valem para projetos populares de código aberto, numa única janela de 12 meses.

Conclusão. São 30 testes (usamos Holm), e o tipo do projeto tem 60 repositórios em 4 grupos, com baixo poder estatístico. As diferenças são associações, não causas. As tags não foram coletadas. A replicação cruzada, com o pipeline de outro grupo, ainda não foi feita.

5. Conclusão

Em 270 repositórios, a entrega medida por releases é moderada: 0,38 releases por semana (Medium) e lead time de cerca de nove dias. A taxa de falha é a métrica mais frágil: 5,3% pelo CI e 40,0% pelas releases corretivas, esta como limite superior. A recuperação tem mediana de 3,2 horas. Velocidade e estabilidade não andam juntas nestes dados ($\rho = 0{,}25$ com o CFR (a)), mas o resultado é em parte mecânico. Idade e contribuidores se associam ao desempenho; estrelas e tipo de projeto, não. A classe DORA muda de 19% a 45% conforme a definição, então comparações entre estudos só fazem sentido com a definição declarada.

Referências

Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum, 2nd edition.

Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382.

Forsgren, N., Humble, J. and Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70.

Landis, J. R. and Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174.

Romano, J. et al. (2006). Appropriate statistics for ordinal level data: should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys? In *Annual Meeting of the Florida Association for Institutional Research*.